

Projet Hetic x Doctolib

**Analyse et prévention en temps réel
des problèmes cardiaques invisibles
pouvant impacter la population.**

Groupe DIA3 2024-2025 :

- RUAN Jiek
- TIBOUCHE Tanya
- ELIDRISSI Yasmine
- LE DEZ Guillaume
- ALKARDO Ibrahim

SOMMAIRE

Analyse d'ECG de patient ayant une maladie cardiaque

1. *Mise en contexte*
2. *Introduction au projet*
 - a. *Le contexte*
 - b. *Le problème*
 - c. *L'hypothèse*
3. *Le cœur de notre projet*
 - a. *Méthodologie et recherches*
 - b. *Nos expérimentations*
 - c. *Comparaison hypothèse et nos tests*
4. *Résultats et analyse*
5. *Conclusion et perspectives*

Innovation technique : Détection des anomalies cardiaques et développement d'une IA spécialisée

Introduction

Les maladies cardiovasculaires constituent la première cause de mortalité dans le monde et une problématique majeure de santé publique en France. En 2023, elles représentaient environ 140 000 décès par an dans le pays, affectant particulièrement les femmes et les personnes âgées. Bien que l'espérance de vie ait augmenté, le nombre d'années vécues en bonne santé est en diminution, souvent en raison de comportements liés au mode de vie, comme la sédentarité et une alimentation déséquilibrée. Les femmes sont particulièrement touchées : 54 % des victimes de maladies cardiovasculaires en France sont des femmes, ce qui en fait leur première cause de mortalité, surpassant les décès par cancer du sein.

Le risque cardiovasculaire augmente avec l'âge et la présence de comorbidités telles que le diabète ou l'hypertension. La prévention joue donc un rôle clé. Des programmes de dépistage et des campagnes de sensibilisation visent à informer la population sur l'importance d'adopter une hygiène de vie saine, intégrant une alimentation équilibrée, une activité physique régulière et l'arrêt du tabac. La prévention précoce et une prise en charge adaptée permettent non seulement de réduire le risque de complications graves, mais également d'alléger le fardeau économique et social des maladies cardiovasculaires.



En France, une véritable mobilisation est en cours pour faire face aux maladies cardiovasculaires, qui touchent des milliers de vies chaque année sans que l'on ne s'en rende compte. Consciente de l'impact dévastateur de ces pathologies, la communauté médicale, les institutions sanitaires, et la société civile travaillent main dans la main pour prévenir, détecter et mieux traiter ces maladies. Des campagnes de sensibilisation sont lancées pour rappeler à chacun l'importance de prendre soin de son cœur : adopter une alimentation équilibrée, bouger davantage, et cesser des habitudes néfastes comme le tabagisme. Ces démarches sont empreintes d'un souci de justice sociale, visant à atteindre aussi les populations les plus vulnérables, souvent exclues des messages de santé publique.

Malgré ces efforts, le défi reste immense. De nombreuses personnes, parfois par manque d'information ou par contraintes sociales, n'ont pas encore accès à une prévention efficace. Il est crucial de faire passer un message clair : chaque geste compte, et chacun peut jouer un rôle dans cette bataille pour la vie. Les maladies cardiovasculaires ne sont pas une fatalité ; ensemble, nous pouvons les vaincre, avec compassion, solidarité, et la volonté de ne laisser personne de côté.

Veille sur les recherches scientifiques existants

Voici quelques recherches que nous avons réalisées pour nous aider dans notre développement de la solution, sur la plateforme arxiv.

ECG Arrhythmia Detection Using Disease-specific Attention-based Deep Learning Model (DANet)

Cet article propose un modèle d'apprentissage profond basé sur une attention spécifique aux maladies pour détecter les arythmies à partir d'enregistrements ECG courts. Le modèle DANet vise à améliorer les performances de classification en se concentrant sur des caractéristiques spécifiques aux maladies.

Lien : <https://arxiv.org/abs/2407.18033>

Electrocardiogram (ECG) Based Cardiac Arrhythmia Detection and Classification using Machine Learning Algorithms

Cet article présente un modèle d'apprentissage profond pour la détection des arythmies, utilisant des données ECG segmentées représentant la distance entre les pics R successifs comme entrée pour un réseau de neurones convolutifs (CNN). L'objectif principal est de développer un système compact pouvant être implémenté dans des dispositifs portables ou des équipements de surveillance en temps réel.

Lien : <https://arxiv.org/abs/2412.05583>

On Arrhythmia Detection by Deep Learning and Multidimensional Representation of ECG Signals

Cette étude convertit les données ECG unidimensionnelles en représentations multidimensionnelles sous forme d'images 2D multicanaux, permettant une extraction de caractéristiques plus riche pour la détection des arythmies. Cette approche vise à capturer des variables cachées telles que les relations de fréquence et la morphologie des segments, non directement accessibles dans le domaine temporel.

Lien : <https://arxiv.org/abs/1904.00138>

End-to-End Optimized Arrhythmia Detection Pipeline using Machine Learning for Ultra-Edge Devices

Cet article propose une pipeline efficace pour la détection en temps réel de la fibrillation auriculaire avec une haute précision, pouvant être déployée sur des dispositifs ultra-edge. L'approche vise à offrir des solutions de santé personnalisées en temps réel, en évitant les problèmes inhérents aux systèmes basés sur le cloud tels que la latence et la dépendance à la connexion réseau.

Lien : <https://arxiv.org/abs/2111.11789>



Comment développer une solution permettant de détecter et prévenir efficacement les anomalies cardiaques, offrant ainsi une réponse à une maladie souvent invisible ?

Rappelons que Les maladies cardiovasculaires, et en particulier les troubles du rythme cardiaque, représentent une des premières causes de mortalité dans le monde, touchant une population de plus en plus large.

Notre études s'est donc concentré sur la détection ainsi que la prévention d'irrégularité cardiaque chez un individu sain ou bien déjà diagnostiqué comme malade. notamment celles liées à des irrégularités des battements cardiaques, qui est un problème de santé souvent silencieux mais mortel. Les symptômes des maladies cardiaques peuvent être invisibles ou masqués jusqu'à ce qu'une crise survienne.

Ainsi, il existe un besoin urgent d'un dispositif accessible, capable de détecter les anomalies cardiaques de manière continue et fiable. Cependant, cette détection précoce nécessite l'utilisation d'outils diagnostiques adaptés, accessibles et capables de traiter efficacement de grandes quantités de données en quasi temps réel pour notre solution

Nous proposons que l'intelligence artificielle, combinée à des outils accessibles comme une carte Arduino A8232 pour l'enregistrement et la récolte des signaux ECG, puisse révolutionner la manière dont les anomalies cardiaques sont détectées à grande échelle.

En réalisant un comparatif sur les modèles d'IA avancés tels que les réseaux neuronaux récurrents (LSTM, GRU) et les Transformers, il est possible de créer un système capable d'identifier de manière fiable et autonome des irrégularités cardiaques avec comme objectif d'atteindre une précision de 99% selon notre seuil de tolérance. Ce système pourrait être intégré à des solutions portables et montre connecté, permettant une surveillance en temps réel et une alerte immédiate en cas de détection d'anomalies pour en notifier le médecin, offrant ainsi un outil de prévention de crise à la portée de tous..

L'apprentissage supervisé et pourquoi ?

Dans notre projet, l'apprentissage supervisé a été privilégié pour plusieurs raisons, en grande partie grâce à la disponibilité de la base de données MIT-BIH Arrhythmia Database, qui offre des annotations fiables et précises sur les types d'arythmies détectées. Voici une explication détaillée de ce choix :

Disponibilité de données étiquetées fiables

La base de données MIT-BIH contient des enregistrements ECG annotés par des experts, avec des labels associés à différents types d'arythmies. Ces annotations permettent de former un modèle en apprentissage supervisé en associant directement les données d'entrée (les signaux ECG) aux sorties attendues (les types d'arythmies).

- L'apprentissage supervisé est particulièrement efficace lorsqu'un dataset de qualité avec des annotations précises est disponible, ce qui est le cas ici.

Optimisation des performances de classification

L'apprentissage supervisé permet de construire un modèle spécifiquement entraîné pour prédire les labels fournis (les catégories d'arythmies dans ce cas). Grâce à des algorithmes comme les LSTM, GRU ou Transformers, il est possible d'optimiser les performances pour :

- Maximiser la précision de la classification.
- Réduire les erreurs de prédiction sur des types d'arythmies rares ou critiques.
- Exploiter les labels pour ajuster les paramètres du modèle en fonction de métriques comme la sparse categorical crossentropy, améliorant ainsi l'apprentissage.

Adaptabilité aux objectifs du projet

L'objectif principal de votre projet est de développer un modèle capable d'identifier des anomalies cardiaques spécifiques et d'informer l'utilisateur. L'apprentissage supervisé est idéal pour ce type de tâche, car il :

- Fournit une correspondance explicite entre les entrées et les sorties.
- Permet de mesurer précisément les performances du modèle en utilisant des métriques comme la précision, le rappel ou l'accuracy.

Limites des autres approches

Apprentissage non supervisé :

- Cette approche est utilisée lorsque les données ne sont pas étiquetées. Bien que cela permette de découvrir des structures cachées ou des groupes dans les données (clustering), elle n'est pas adaptée ici car votre projet nécessite de prédire des classes définies (les types d'arythmies).
- De plus, l'absence de supervision limite la possibilité de valider facilement les résultats obtenus.

Apprentissage semi-supervisé :

- Cette méthode combine données étiquetées et non étiquetées. Cependant, la MIT-BIH offre un dataset entièrement annoté, rendant l'apprentissage semi-supervisé moins pertinent dans ce cas.

Apprentissage par renforcement :

- Bien que puissant pour des tâches interactives ou séquentielles, il n'est pas adapté à votre problématique, car celle-ci ne consiste pas à prendre des décisions dans un environnement dynamique, mais plutôt à classifier des signaux ECG statiques.

Efficacité et rapidité de développement

L'apprentissage supervisé, grâce à l'utilisation de bases de données étiquetées comme MIT-BIH, permet un entraînement plus direct et une validation plus simple par rapport aux approches non supervisées ou semi-supervisées. Cela réduit le temps et les ressources nécessaires pour obtenir un modèle performant.

En conclusion :

L'apprentissage supervisé a été choisi pour sa capacité à exploiter efficacement une base de données riche et annotée comme MIT-BIH, permettant de construire un modèle précis et fiable pour la détection des arythmies. Cette approche garantit une validation rigoureuse et des performances optimales, en ligne avec les objectifs de votre projet.


Keras ? TensorFlow ? Mais à quoi ça sert ?

Keras, intégré à TensorFlow, est une bibliothèque de haut niveau conçue pour simplifier la création de modèles d'apprentissage profond. Dans notre projet, nous l'utilisons pour :

- **Créer et structurer des modèles** : avec des architectures comme **LSTM**, **GRU**, ou **Transformers**, en empilant des couches de manière intuitive.
- **Configurer l'entraînement** : grâce à des fonctions comme **ReduceLROnPlateau** et **EarlyStopping**, vous pouvez optimiser le processus d'entraînement en ajustant dynamiquement les hyperparamètres comme le taux d'apprentissage.
- **Suivre les performances** : avec des métriques comme **Recall**, **confusion_matrix**, et **ROC curves**, pour évaluer la qualité de la détection des anomalies ECG.
- **Personnalisation avancée** : par exemple, l'intégration de mécanismes d'attention ou la gestion de configurations complexes via des callbacks et des schedules.

Pourquoi Keras ?


Keras est particulièrement utile ici pour sa simplicité et son intégration étroite avec TensorFlow, offrant des outils performants pour traiter des données séquentielles comme les signaux ECG tout en réduisant la complexité du développement.



Les maladies cardiaques cibles

Voici les maladies cardiaques que nous allons cibler avec notre modèles

Pourcentage de Patients par Classe de Maladie Cardiaque



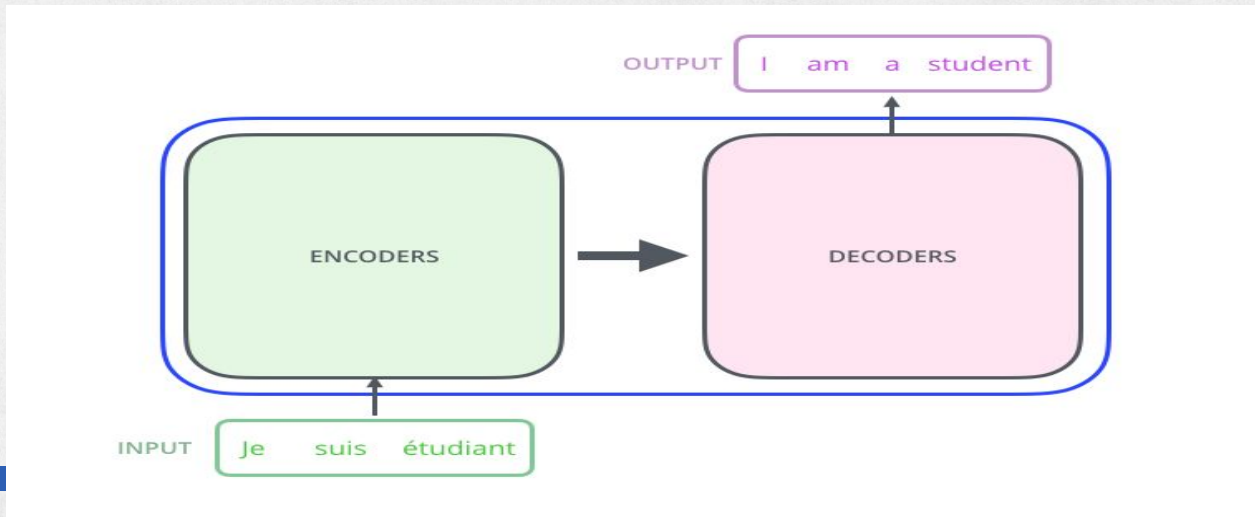
On trouve 5 classes différentes :

- 0 : normal -> 82.8%
- 1: Extrasystole supraventriculaire (supraventricular ectopic beat) -> 2.5%
- 2 : Extrasystole ventriculaire (ventricular ectopic beat) ->6.6%
- 3 : Battement de fusion (fusion beat) -> 0.7%
- 4 : inconnu -> 7.3%

Classe	Moyenne	Variance	Corrélation Moyenne
Normal	0.1738	0.0342	0.9425
Supraventricular ectopic beat	0.1812	0.0260	0.8938
Ventricular ectopic beat	0.2493	0.0471	0.9076
Fusion Beat	0.1056	0.0136	0.9612
Inconnu	0.2532	0.0281	0.9581

Objectif :

Trouver le modèle adapté à l'analyse des données de types ECG, de trouver le pas d'apprentissage optimal, la bonne loss pour le modèle, l'optimizer ainsi que le nombre de lot idéal.



L'importance des paramètres pour notre modèle

Quels sont les points forts de chaque modèle ?

Modèles LSTM : LSTM est un type de réseau neuronal récurrent (RNN) conçu pour traiter les séquences de données tout en gérant les dépendances à long terme grâce à des mécanismes de portes (forget gate, input gate, output gate).

Conclusion : Très efficace pour les données temporelles comme les ECG où les signaux complexes nécessitent une mémoire sur plusieurs instants.

Modèles GRU : Variante simplifiée du LSTM, avec moins de paramètres et une architecture plus légère, ce qui le rend souvent plus rapide à entraîner.

Conclusion : Idéal pour des tâches où la vitesse d'entraînement est cruciale sans sacrifier significativement la performance.

Modèles Transformers : ils utilisent des mécanismes d'attention pour traiter les relations entre les différentes parties des séquences, permettant un traitement parallèle et une compréhension globale des données.

Conclusion : Efficace pour les données ECG à haute fréquence ou pour les tâches nécessitant un contexte global.

L'importance des hyperparamètres

Définition :

Taux d'apprentissage (Learning Rate) : Un taux trop élevé empêche la convergence ou provoque des oscillations. Un taux trop faible ralentit l'entraînement et risque de piéger le modèle dans des minima locaux.

La fonction de perte (loss function) : mesure la différence entre les prédictions du modèle et les valeurs réelles, guidant l'ajustement des poids du modèle. Une loss mal adaptée peut ralentir ou compromettre l'entraînement du modèle. Choisir la bonne loss dépend du problème et du type de sortie attendu.

L'optimiseur (optimizer) : ajuste les poids du modèle pour minimiser la perte.

Le batch (lot) : correspond au nombre d'échantillons traités avant une mise à jour des poids du modèle. Trouver le compromis idéal dépend de la mémoire GPU disponible et de la complexité des données ainsi que de notre connaissance sur le jeu de donnée.

Le réglage des hyperparamètres est crucial dans l'entraînement des modèles d'apprentissage automatique car ces paramètres contrôlent le fonctionnement interne du modèle et influencent directement ses performances. Des hyperparamètres comme le taux d'apprentissage, la taille du batch, ou les coefficients de régularisation déterminent à quel point le modèle apprend efficacement à partir des données d'entraînement et évite des problèmes comme le surajustement ou le sous-ajustement. Par exemple, un taux d'apprentissage mal ajusté peut soit ralentir considérablement la convergence, soit empêcher le modèle de trouver une solution optimale. De même, une taille de batch inappropriée peut nuire à la stabilité ou à la rapidité de l'apprentissage.

En optimisant ces hyperparamètres, on maximise la capacité du modèle à généraliser sur des données non vues, tout en minimisant le temps de calcul. Cela est particulièrement important dans des applications sensibles comme la détection des irrégularités cardiaques, où une mauvaise configuration pourrait compromettre la précision et la fiabilité du système. Ainsi, un réglage judicieux des hyperparamètres, souvent basé sur des expérimentations ou des recherches automatisées (comme la recherche sur grille ou bayésienne), permet d'équilibrer efficacement la performance et la complexité du modèle.

Point d'attention : nous devons évidemment en amont avoir un jeu de donnée normaliser, propre sans donnée manquante ou de donnée null. Nous devons éviter que le modèle sur des informations qui pourrait l'induire en erreur comme confondre une donnée null avec un battement cardiaque irrégulier.

Tableau de test des modèles : Comparatif des performances des modèles sur le jeu de donnée du MIT-BIH

	Accuracy	Loss	Val_accuracy	Val_loss
LSTM	0.9458	0.1378	0.9461	0.1363
LSTM avec Attention	0.9678	0.0901	0.9814	0.0655
GRU	0.9647	0.0941	0.9770	0.0665
GRU avec Attention	0.9545	0.1155	0.9618	0.1093
Transformer learning_rate: 6.2500e-06	0.9954	0.0140	0.9934	0.0244

Learning rate : 0.0001

Batch_size : 128

Loss : Sparse Categorical Crossentropy

Validation Split : 0.15

Epoch : 30

Nous avons opté pour notre projet un modèle Transformer en raison de ses performances remarquables dans la modélisation des séquences temporelles complexes comme les signaux ECG. Contrairement aux architectures classiques telles que LSTM ou GRU, les Transformers tirent parti du mécanisme d'attention, qui leur permet de capturer efficacement les relations à longue portée entre les données tout en offrant une meilleure parallélisation pendant l'entraînement.

Lors de nos tests, nous avons également exploré les variantes LSTM et GRU avec des mécanismes d'attention. Bien que LSTM ait montré des résultats satisfaisants, le GRU avec attention a perdu en performance. Cela peut s'expliquer par la simplification des portes dans GRU par rapport à LSTM, ce qui peut rendre ce dernier moins performant pour des tâches complexes nécessitant une gestion fine des dépendances temporelles. L'ajout de l'attention n'a pas compensé cette limitation, ce qui explique son résultat inférieur.

Passons un peu plus de temps sur les hyperparamètres que nous avons choisis pour entraîner notre modèle.

Learning Rate : 0.0001

Le choix d'un faible taux d'apprentissage est crucial pour optimiser la convergence du modèle Transformer. Un taux élevé pourrait entraîner une oscillation ou un échec à atteindre le minimum global, tandis qu'un taux trop faible ralentirait considérablement l'entraînement. Le taux de 0.0001 s'est avéré efficace pour un équilibre entre stabilité et vitesse d'apprentissage.

Batch Size : 128

Une taille de lot de 128 permet de tirer parti des ressources disponibles tout en assurant une estimation fiable des gradients. Un lot trop petit pourrait introduire du bruit, alors qu'un lot trop grand augmenterait le temps de calcul et nécessiterait une plus grande mémoire GPU.

3. Loss : Sparse Categorical Crossentropy

Cette fonction de perte est particulièrement adaptée à notre tâche de classification multicatégorie. Elle compare directement les classes prédictives du modèle à leurs vraies classes, en tenant compte du fait que les données de sortie sont codées sous forme d'index entiers.

Validation Split : 0.15

Nous avons réservé 15 % des données d'entraînement pour la validation, afin de surveiller les performances du modèle et d'éviter le surajustement. Ce ratio garantit une taille suffisante pour l'évaluation tout en laissant une grande majorité des données pour l'entraînement.

Point d'attention : Pour cette partie nous avons du shuffle notre jeu de donnée car il trier de 0-4 par classe de maladie cardiaque avec en 0 (les personnes en bonnes santés) et donc dans les 15% nous nous retrouvons uniquement avec des personnes en bonnes santés ce qui avait faussé notre premier entraînement.

Epoch : 30

Le nombre d'époques a été fixé à 30 après plusieurs essais. Cette durée est suffisante pour permettre au modèle d'apprendre sans surapprentissage, détecté via la stagnation ou la détérioration de la performance de validation.

Optimizer : Adam

L'optimiseur Adam est un choix populaire pour sa capacité à ajuster dynamiquement le taux d'apprentissage en fonction des gradients. Cela permet une convergence plus rapide et stable, surtout dans les architectures complexes comme le Transformer.

Ce choix d'hyperparamètres a permis d'optimiser la performance de notre modèle, tout en garantissant une convergence stable et efficace dans le cadre de notre tâche de détection des irrégularités cardiaques.

Courbe ROC (Receiver Operating Characteristic)

Explication simplifiée de la courbe ROC

La **courbe ROC** est un outil graphique utilisé pour évaluer les performances d'un modèle de classification, en particulier dans des contextes où les classes sont déséquilibrées (par exemple, identifier des battements cardiaques irréguliers au milieu de données normales).

Que montre la courbe ROC ?

1. **Axe des Y : le taux de vrais positifs (sensibilité)**, c'est-à-dire la capacité du modèle à détecter correctement les cas positifs (par exemple, les battements anormaux). Les patients dit non-malades hors ils sont malades
2. **Axe des X : le taux de faux positifs**, soit la proportion de cas normaux incorrectement classés comme anormaux. Ici les patients dit malades hors ils ne le sont pas.

Chaque point sur la courbe correspond à un seuil différent utilisé pour séparer les classes.

Pourquoi est-elle utile ?

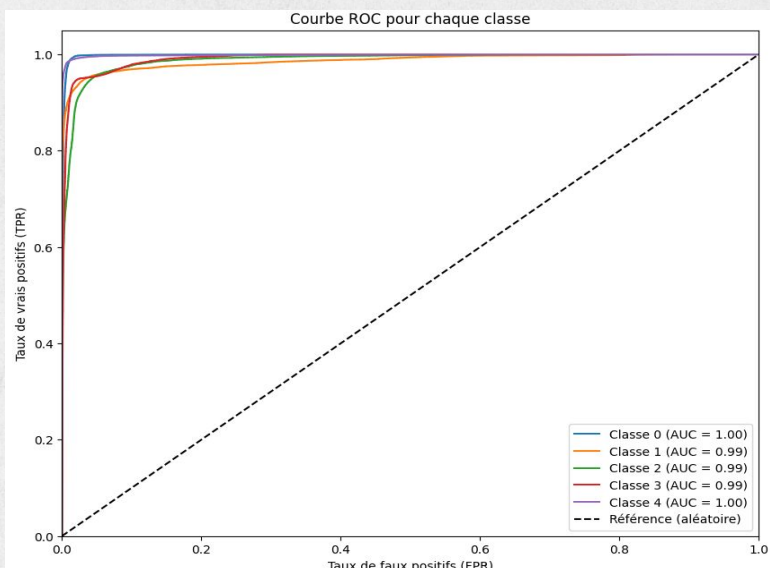
- **Performance globale du modèle** : Plus la courbe est proche du coin supérieur gauche, meilleur est le modèle. Cela indique une sensibilité élevée (bons positifs détectés) et peu de faux positifs.
- **Aire sous la courbe (AUC)** : Une valeur AUC proche de 1 indique un excellent modèle, tandis qu'une valeur de 0.5 montre une performance équivalente au hasard.

Seuil de tolérance optimal

La courbe ROC aide également à choisir un **seuil optimal** pour classer les données :

- Un seuil trop bas : augmente la sensibilité mais génère plus de faux positifs.
- Un seuil trop haut : réduit les faux positifs mais peut manquer des vrais cas positifs.

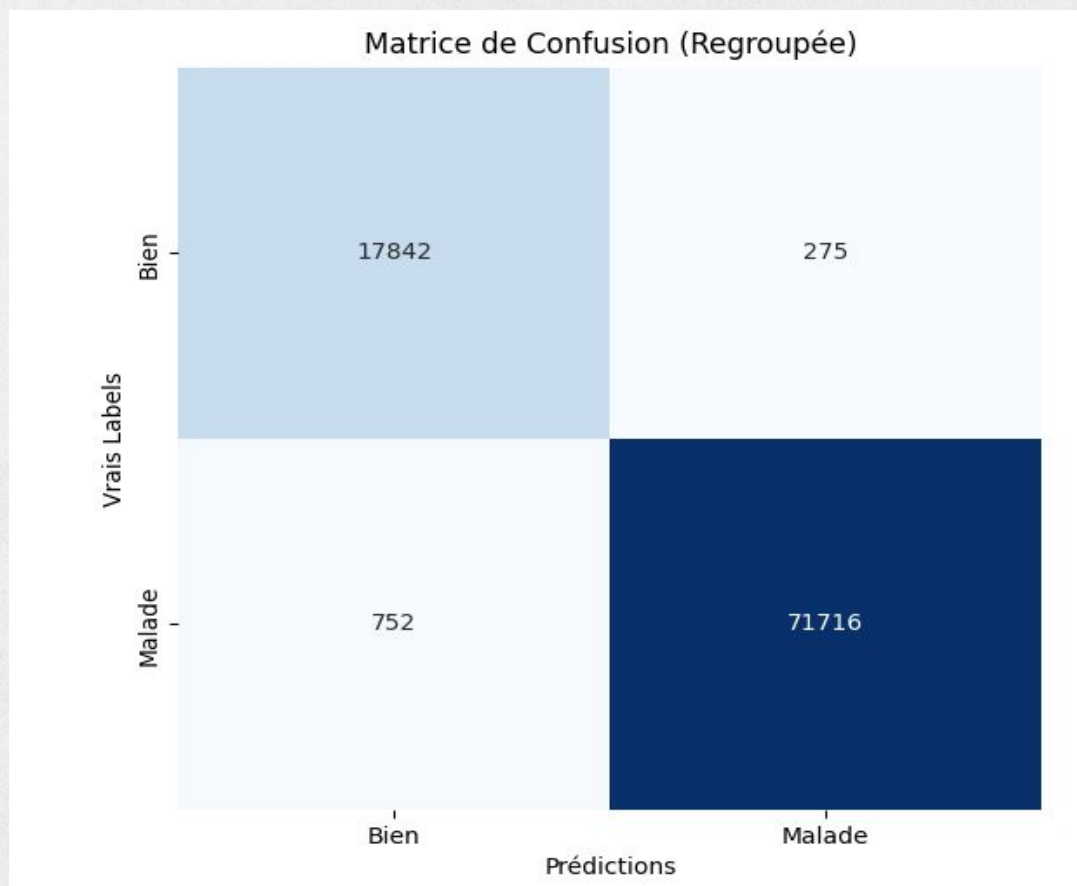
En pratique, on choisit un seuil qui équilibre la sensibilité et la spécificité en fonction des besoins de notre projet. Effectivement en fonction des besoins le seuil sera modifié.



Notre courbe semble très convaincante. La courbe révèle une excellente performance globale de votre modèle, avec des AUC proches de 1 pour toutes les classes, démontrant une grande précision dans la détection des anomalies. Les courbes, très proches de l'angle supérieur gauche, reflètent une sensibilité élevée et un faible taux de faux positifs. De plus, elles sont nettement éloignées de la référence aléatoire, confirmant la fiabilité du modèle.

Conclusion

Ce projet a permis de développer un modèle performant et fiable pour détecter les anomalies cardiaques, en s'appuyant sur des données robustes issues de la base MIT-BIH. Grâce à l'utilisation d'une architecture basée sur les Transformers et à un réglage minutieux des hyperparamètres, nous avons atteint des performances plus que convenable pour notre projet, comme en témoigne l'excellente précision illustrée par des courbes ROC aux AUC proches de 1 pour toutes les classes. Cette avancée constitue une étape importante vers une détection précoce et automatisée des troubles cardiaques, avec un potentiel impact positif sur la réduction des risques et une amélioration significative de la prise en charge des patients.



Nous avons dans notre matrice comparé le vrai positif, le vrai négatif, le faux positif ainsi que le faux négatif. Notre point d'attention a été sur le faux positif (en bas à gauche) car nous devons à tout prix éviter de dire à un patient qu'il n'est pas malade alors qu'il est belle et bien malade. Donc notre modèle a obtenu un résultat très satisfaisant car sur plus près de 73 000 patients nous avons 752 erreurs du modèle, cela reste effectivement beaucoup car nous voulons être proche de 100% de réussite.

Perspectives d'Avenir

1. **Améliorations Techniques**

Pour aller plus loin, nous envisageons d'explorer des architectures encore plus avancées, notamment des Transformers hybrides ou des combinaisons avec d'autres techniques comme les modèles CNN-LSTM, afin d'améliorer davantage la précision.

De plus, intégrer des données issues de diverses sources et populations permettra de généraliser les performances du modèle à un plus large éventail de cas.

2. **Applications Pratiques**

L'une des principales perspectives est le développement d'un prototype de dispositif portable capable de collecter des signaux ECG en temps réel et de les analyser grâce à notre modèle. Une telle solution pourrait permettre un suivi continu à domicile sur montre connectée, offrant ainsi une sécurité accrue pour les patients à risque et une alerte rapide en cas de détection d'anomalies.

3. **Défis Éthiques et Réglementaires**

La mise en œuvre de cette solution dans un contexte pratique nécessite de répondre aux enjeux de confidentialité des données médicales, en conformité avec le RGPD. En parallèle, une certification en tant qu'outil médical fiable devra être obtenue pour garantir son utilisation dans un cadre clinique.

4. **Extension des Fonctionnalités**

Une piste intéressante serait d'élargir les capacités du modèle pour inclure la prédiction des risques de pathologies futures basées sur les signaux ECG historiques. De plus, le modèle pourrait être optimisé pour détecter une gamme plus large d'anomalies cardiaques, comme les bradycardies ou les tachycardies, augmentant ainsi son utilité clinique. Nous n'avons que 4 types de maladies cardiaques sur notre modèle hors ils en existent près de 30.

5. **Collaboration Interdisciplinaire**

La réussite du déploiement de cette technologie nécessitera des collaborations étroites avec des cardiologues, des spécialistes en dispositifs médicaux connectés et des chercheurs en intelligence artificielle. Ces partenariats permettront de valider le modèle dans des environnements réels, d'assurer une adoption efficace et d'améliorer continuellement ses performances.